

Nama : Laudya Meitaneia Sianturi

NPM : 24083010089

CVE & GitHub Advisory Database sebagai Ekosistem Big Data Keamanan Siber

Tugas Esai Pengganti Perkuliahan Big Data Kelas C

1. Pendahuluan


Ancaman keamanan siber tumbuh dengan kecepatan dan kompleksitas yang melampaui kemampuan pemantauan manual. Common Vulnerabilities and Exposures (CVE), dikelola MITRE dan didistribusikan melalui National Vulnerability Database (NVD) NIST yang merupakan sistem identifikasi kerentanan perangkat lunak yang telah mempublikasikan lebih dari 230.000 entri sejak 1999. Di sisi lain, GitHub Advisory Database menambahkan lapisan ekosistem berbasis komunitas: setiap commit, pull request, dan security advisory yang berkaitan dengan kerentanan tercatat secara real-time oleh ratusan juta pengembang. Gabungan keduanya membentuk ekosistem big data keamanan siber yang sangat relevan karena menyentuh langsung rantai pasok perangkat lunak global dari aplikasi perbankan, infrastruktur kritis, hingga perangkat IoT yang digunakan jutaan orang.



Gambar 1. Ekosistem Threat Intelligence konteks pemanfaatan data CVE & GitHub Advisory.


2. Analisis Aspek Big Data (7V)

1. Volume: NVD mencatat lebih dari 34.000 CVE baru sepanjang 2024 saja, dengan total basis data melampaui 230.000 entri. GitHub menyimpan miliaran baris kode dari lebih 420 juta repositori, di mana setiap perubahan kode yang mengandung perbaikan kerentanan menjadi sinyal data berharga.



Gambar 2. Pertumbuhan jumlah CVE dipublikasi per tahun 2019–2024 (NVD/NIST).

2. Velocity: CVE baru diterbitkan setiap jam; eksploitasi zero-day dapat muncul dan menyebar dalam hitungan menit setelah pengungkapan. GitHub menerima jutasi push event per hari. Kecepatan ini menuntut pipeline streaming (seperti Apache Kafka) agar tim keamanan dapat merespons sebelum aktor jahat memanfaatkan kerentanan yang baru dipublikasi.
3. Variety: Data keamanan hadir dalam beragam format: entri terstruktur JSON/XML (NVD feeds), kode sumber (Python, C, Java), laporan bug bounty semi-terstruktur, diskusi isu GitHub teks bebas, metadata paket (npm, PyPI, Maven), dan aliran jaringan dari honeypot. Ekosistem big data keamanan siber pada dasarnya mengelola data mulai dari yang terstruktur penuh (Data Warehouse) hingga data mentah tak berstruktur (Data Lake), bahkan kombinasi keduanya melalui pendekatan Data Lakehouse.



Gambar 3. Evolusi arsitektur Data Warehouse → Data Lake → Data Lakehouse, relevan untuk mengelola variety data CVE.

4. Veracity : Tidak semua CVE memiliki skor CVSS yang akurat, sekitar 15% entri pernah direvisi setelah publikasi awal. Duplikasi terjadi saat kerentanan yang sama dilaporkan beberapa peneliti dengan nomor berbeda. NVD dan GitHub Advisory bersifat terbuka, namun feed premium vendor intelijen ancaman sering terfragmentasi di balik paywall.
5. Variability: Intensitas publikasi CVE tidak konstan: lonjakan masif terjadi setelah pengungkapan kerentanan besar seperti Log4Shell (Desember 2021). Variabilitas ini menyulitkan perencanaan kapasitas sistem analitik yang harus mampu menangani spike trafik ekstrem.
6. Validity: False positive mengurangi presisi model prediktif dan berpotensi mengakibatkan prioritas penambalan yang keliru.
7. Value : Nilai ekosistem ini sangat tinggi: dengan mengkorelasikan CVE terhadap daftar dependensi perangkat lunak (Software Bill of Materials/SBOM), tim keamanan dapat memprioritaskan penambalan berdasarkan risiko nyata seperti yang ditampilkan fitur Dependabot Alerts pada GitHub yang secara otomatis mendeteksi dependensi rentan dalam repositori.

3. Usulan Peningkatan Ekosistem

(1) integrasi SBOM otomatis dengan CVE feed real-time. Setiap repositori GitHub seharusnya diwajibkan menyertakan SBOM tervalidasi (CycloneDX atau SPDX), sehingga sistem dapat otomatis mencocokkan dependensi dengan CVE baru yang masuk dan mengirim notifikasi prioritas dan mempersingkat waktu respons dari berhari-hari menjadi menit. (2) Model ML prediktif untuk skor risiko kontekstual. Skor CVSS bersifat generik. Dengan melatih model gradient boosting pada fitur tipe CWE, ketersediaan exploit publik, popularitas paket, dan riwayat insiden, sistem menghasilkan skor risiko yang jauh lebih relevan untuk infrastruktur spesifik setiap organisasi. (3) Arsitektur Data Lakehouse untuk intelijen ancaman terpadu. Pendekatan Lakehouse memungkinkan data CVE terstruktur (JSON/NVD) dan data tidak terstruktur (kode sumber, laporan insiden) disimpan dan dianalisis dalam satu platform, mendukung baik analitik real-time maupun pemodelan ML jangka Panjang

4. Kesimpulan

Ekosistem CVE dan GitHub Advisory Database merepresentasikan implementasi big data paling kritis di era digital. Dengan volume yang terus meningkat, kecepatan publikasi tinggi, dan keragaman format data, ekosistem ini memberikan nilai strategis besar dalam perlindungan rantai pasok perangkat lunak global. Tantangan pada aspek veracity dan validity perlu diatasi melalui otomatisasi validasi silang dan model kontekstual berbasis ML. Dengan penguatan integrasi SBOM, analitik prediktif, dan arsitektur Data Lakehouse, ekosistem ini berpotensi menjadi tulang punggung pertahanan siber kolektif termasuk bagi Indonesia.

*Referensi: NIST NVD (2024) nvd.nist.gov; MITRE (2024) cve.org; GitHub (2024) [Advisory Database & Dependabot](https://github.com/advisory); FIRST.org (2023) *CVSS v3.1 Specification*; Sabetta & Bezzi (2018) *ICSME*.*